

# 최신 퀀텀 딥러닝 기술 동향

김중헌, 윤원준, 백한결, 김재평 (고려대학교 전기전자공학부)

## I. 서론

2019년 구글에서 개발한 53큐비트 양자 컴퓨터를 이용하여 기존 슈퍼컴퓨터에서 1만년이 걸릴 문제를 단 3분 20초만에 풀어 화제가 되었다 [1]. 이러한 양자 컴퓨터의 발전에 힘입어, 다양한 양자 알고리즘을 실제 양자 컴퓨터를 활용하여 입증하는 연구가 활발하게 이루어지고 있다. 예를 들어, 양자 근사 최적 알고리즘 (QAOA: Quantum Approximate Optimization Algorithm)을 활용하여 Min-cut, Max-cut 등의 조합 최적화 문제를 푸는 방향으로 진행되고 있다 [2-5].

이러한 문제 해결의 원리는 양자 중첩에 있다. 고전 컴퓨터가 사용하는 이진 비트 (bit)와는 다르게, 양자 컴퓨터에서 사용하는 큐비트 (Qubit: Quantum bit)은 0과 1을 동시에 지닐 수 있는 특성이 있으며, 다중 큐비트 시스템에서도 중첩이 가능하여 많은 양의 정보를 동시에 처리할 수 있는 특성이 있다. 10 큐비트가 중첩되어 있다면, 지닐 수 있는 정보의 양은 총  $2^{10}$ 이 되는 원리이다.

본 논문에서는 이러한 큐비트 특성을 활용한 양자 머신러닝에 대해 논한다. 양자 머신러닝은 양자 컴퓨팅 플랫폼의 발전에 따라 크게 발전하게 되었다. 2019년 10 큐비트 양자 컴퓨터를 일부 클라우드에서만 이용이 가능했지만, 현재 127큐비트 양자 컴퓨터를 클라우드 서비스를 통해 이용이 가능하다. 또한 IBM Quantum 로드맵 2022에 따르면, 2023년까지 1,000 큐비트 컴퓨터 개발, 2026년까지 10만 큐비트 컴퓨터를 개발한다는 내용이 발표되었다. 즉, 양자 잡음이 무시 가능한 스케일 (NISQ: Noise Intermediate-Scale Quantum)의 양자 컴퓨팅 규모를 벗어나, beyond NISQ의 시대가 열리는 것이다.

양자 머신러닝 플랫폼의 비약적 발전이 있었다. 과거, Qiskit 및 Google Cirq (Tensorflow Quantum)만 있었는데, 현재 양자 클라우드와 결합하여 사용자의 특성을 고려한 Xanadu의 PennyLane과 TorchQuantum도 출시하였다. 이러한 폭발적인 인프라 구축은 양자 머신러닝은 이진 분류 모델 (Classifier), 이진 생성 모델 (Generative model), 단일변수 회귀 (Regression) 문제를 넘어서서 고전 컴퓨팅을 활용한 인공지능의 과업인 이미지 분류, 강화학습, 패턴인식 등으로 다양하게 활용되고 있다 [6-11].

양자 머신러닝은 변형 양자 회로 (VQC: Variational Quantum Circuit)을 최적화하여 목적을 달성하는 방법이며, 문제 설계에 집중하기 보다는 데이터와 레이블로 학습을 시키는 방법 중 하나이다. 시벤코 정리 (Universal Function Approximation Theorem)는 선형 연산과 활성화 함수가 존재할 때, 어떠한 연속함수를 근사한다는 정리이다. 양자 머신러닝의 인공신경망 격인 변형 양자 회로는 모든 연산이 유니터리 연산 (Unitary Operation)이며, 모든 유니터리 연산은 선형 연산이고 또한, 양자 측정은 활성화 함수이기 때문에 시벤코 정리를 만족하며, 양자 딥러닝을 가능케 하였다.

양자 딥러닝은 현재 지도 학습, 비지도 학습, 적대적 학습, 강화 학습, 연합 학습 등 다양한 알고리즘에 대해서 연구 되어 왔으며, 회로 단에서의 연구부터 다양한 어플리케이션에 이르기까지 주로 일반적으로 사용되는 뉴럴네트워크와 동일 파라미터 수를 사용하였을 때 양자 회로를 사용하였을 때 성능이 더 좋다는 점에 착안하여 접근하였다 [12-15].

퀀텀 머신러닝의 비지도 학습에 대한 가능성이 입증되

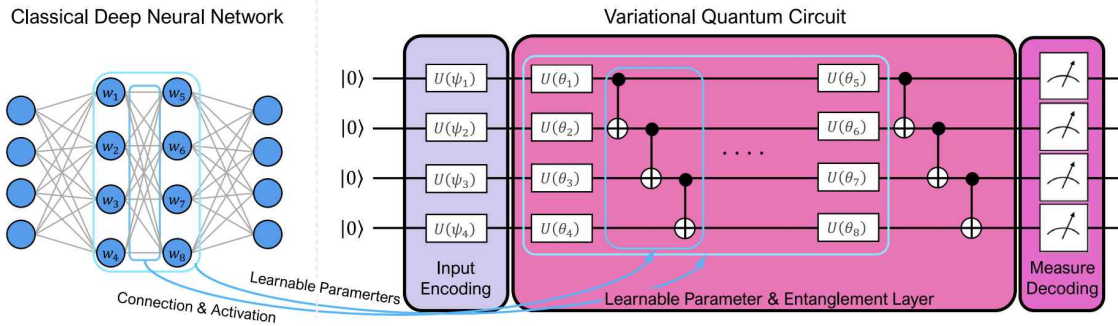


그림 1 양자 인공지능망과 고전 인공지능망의 구조적 차이 [14]

면서, 쿼텀 심층 강화학습 (QDRL: Quantum Deep Reinforcement Learning)에 대한 연구도 활발하게 진행되고 있다 [16-20]. 이러한 양자 컴퓨팅 연구의 흐름에 따라, 본 논문에서는 양자 딥러닝에서부터 양자 강화학습, 양자 분산 학습에 이르기까지 다양한 응용 모델들의 연구 발전 방향에 대하여 알아보고, 각각의 성능을 최적화하기 위하여 기연구된 다양한 방법론들에 대하여 알아본다. 이에 더하여, 각각의 응용 모델들이 직면한 문제점들과 발전 가능성을 간략히 논하여, 다가오는 beyond NISQ 시대에 발맞추어 양자 컴퓨팅 연구 방향을 제시한다.

## II. 양자 딥러닝

양자 컴퓨터의 발전에 발맞추어 현존하는 많은 딥러닝 알고리즘을 양자 컴퓨팅을 이용하여 최적화하려는 연구들이 진행되었다. 이러한 양자 딥러닝 (QDL: Quantum Deep Learning) 연구들은 양자 컴퓨팅과 딥러닝의 접목을 통하여, 딥러닝 연산의 지수적인 속도개선을 이루고자 하였다. 이러한 양자 딥러닝은 기본적으로 양자 컴퓨팅의 기본 유닛인 큐비트 (Qubit)의 변환 연산을 통하여 이루어진다. 양자 딥러닝은 크게 세 과정을 통하여 나타낼 수 있다. 이는 인코딩(Encoding), 양자 회로 내에서의 변환 연산, 측정(Measurement)이다. 이 과정을, 본격적인 양자 딥러닝 연구 근황에 앞서, 간단히 살펴보자면 다음과 같다. 우선, 인코딩 단계에서는 기존의 컴퓨팅에서 사용되는 비트(Bit)로 이루어진 데이터를 양자의 큐비트의 상태(State)로 치환하는 과정이 이루어진다. 대표적으로, 기저 인코딩(Basis Encoding), 각 인코딩(Angle Encoding) 등 인코딩 방법을 통하여 데이터를 인코딩한다 [7]. 이후, 서론에서 언급한 유니타리 연산 및 측정을 통하여 최적화하고자 하는 목적 식에 맞게 각

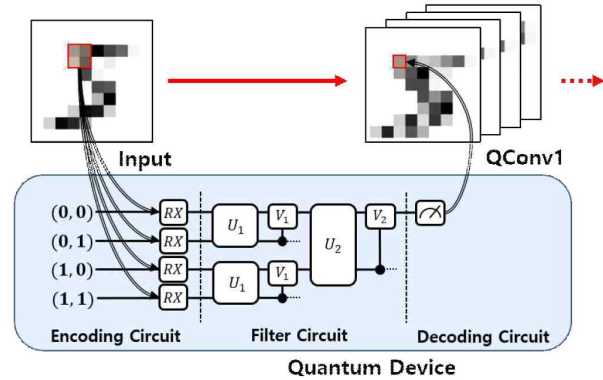


그림 2 Quantum Convolution [7]

각의 유니타리 행렬의 파라미터들을 학습되게 된다. 양자 회로를 지나 온 큐비트를 다시 비트로 변환하기 위해서 측정이 이루어진다. 이후, 측정을 통하여 나온 값을 통하여 기존 인공지능망이 수행하였던 목적을 달성하는 것이 양자 딥러닝의 주요 골자이다.

양자 딥러닝을 실제 상용화하기 위해서 크게 두 가지 접근 방법이 고려되고 있다. 첫째는 VQC의 측정 이후 나온 비트 데이터를 그대로 사용하는 양자 딥러닝 모델이다. 이 경우, 양자 컴퓨터만을 사용하여 학습 및 추론 가능하여 그 활용성이 뛰어나지만, 측정 단계에서 얻을 수 있는 비트 데이터가 한정적이기에 다중 분류 모델 (Multi-class Classification)에 사용하기 위해서는 극복해야만 하는 제약이 존재한다. 둘째는 측정 이후 나온 비트 데이터에 인공지능망의 완전 연결 계층 (FCN: Fully Connected Layer)를 연결하여 사용하는 하이브리드 양자 모델이다. 이는 완전 연결 계층을 사용함으로써, 다중 분류 모델 등을 사용할 수 있지만, 양자 컴퓨팅의 연산 상에 얻을 수 있는 장점을 최대한으로 이끌 수 없다는 제약이 존재한다. 그림. 1[14]은 VQC를 이용한 양자 딥러닝 분류 모델과 기존 인공지능망의 구조적 차이를 나타낸다. 우선, 훈련 데이터 입력값은 VQC를 운용할 수 있도록 인코딩 단계에서 큐비트로 인코딩된다. 이러한 양자 상태는 인공지능망 역할을 대신할 수 있는 VQC

에 전달된다. 이후, 다양한 유니터리 연산을 통하여 양자 상태가 변환된 후, 측정을 통하여 이진 비트 데이터를 얻게 된다.

이와 같은 VQC 기반 양자 딥러닝을 학습하기 위해서는 병목 현상(Barren Plateaus)을 해결해야 한다. 큐비트가 지수적인 정보를 포함하고 있기에, VQC 내의 큐비트의 개수 증가는 병목 현상을 일으켜, 양자 딥러닝 모델의 학습을 방해하는 요소로 작용한다. 이를 해결하기 위한 다양한 방법 중 대표적으로, 양자 합성곱 신경망(QCNN: Quantum Convolutional Neural Network)가 제안되었다. 그림 2는 양자 합성곱 신경망의 구조를 나타낸다. 양자 합성곱 신경망은 VQC 구조를 기존 합성곱 신경망의 필터와 같이 활용하여 인풋 벡터 공간을 이동(Stride)하여 특성 값(Feature)을 추출하도록 설계되었다. 이러한 필터를 양자 합성곱 필터(Quantum Convolutional Filter)라 하며, 각 단계에서의 측정을 통하여 폴링 연산이 일어나 VQC 고유의 병목 현상을 해결하여 학습을 보장한다. 이러한 양자 합성곱 신경망의 우수성을 바탕으로 하여 이를 하이브리드 모델로 만들어 다중 분류 모델을 만드는 연구가 이어 진행되었다. 그림 3은 양자 합성곱 신경망을 측정하여 나온 이진 비트에 완전 연결 계층을 연결하여 다중 분류를 가능하게 하는 모델 구조를 개괄적으로 나타낸다. 하이브리드 양자 합성곱 신경망의 연구를 통하여 양자 딥러닝을 통한 다중 분류 모델의 가능성이 확인되었다.

하지만, 이러한 하이브리드 양자 합성곱 신경망 또한 병목 현상을 회피하기 위해서 입력 큐비트의 개수를 제한하게 되고, 이는 곧 측정에서 얻을 수 있는 특성 값의 제약으로 이어져 분류 모델의 성능 저하로 이어질 수 있다. 이를 해결하기 위하여, 확장성 있는 양자 합성곱 신




그림 3 이진비트 양자 QCNN [24]

경망(sQCNN: scalable Quantum Convolutional Neural Network)이 연구되었다.[18]. 확장성 있는 양자 합성곱 신경망은 양자 합성곱 신경망의 특성 값의 개수를 늘려 분류 모델의 성능을 개선하기 위하여, 다양화된 많은 개수의 특성 값을 얻기 위하여 양자 합성곱 필터의 큐비트의 개수는 동일하게 유지하면서, 양자 합성곱 필터의 개수를 늘렸다. 그림 4는 확장성 있는 양자 합성곱 신경망과 양자 합성곱 신경망의 구조적 차이를 나타낸다.

### III. 양자 심층 강화 학습

심층 강화 학습 (Deep Reinforcement Learning)은 2010 년도 이후에 발전을 거듭하여 통신 및 ICT 분야에서 효율적인 최적화 기법으로 널리 사용되고 있다. 하지만 심층 강화 학습에서도 방대한 계산량을 가진 문제들이 존재하여, 이런 문제들을 풀기 위해서 과도한 자원과 시간이 필요했다. 이런 한계점을 극복하기 위해 양자 컴퓨팅을 사용하는 양자 심층 강화학습 (Quantum Deep Reinforcement Learning)이 새로운 해결 방법으로 관심을 받고 있다. 양자 심층 강화학습은 고전적인 강화학습을 양자 컴퓨팅을 이용하여 구현하는 기법으로, 양자 컴퓨팅의 증강된 연산량을 활용하고자 한다. 양자 심층 강화학

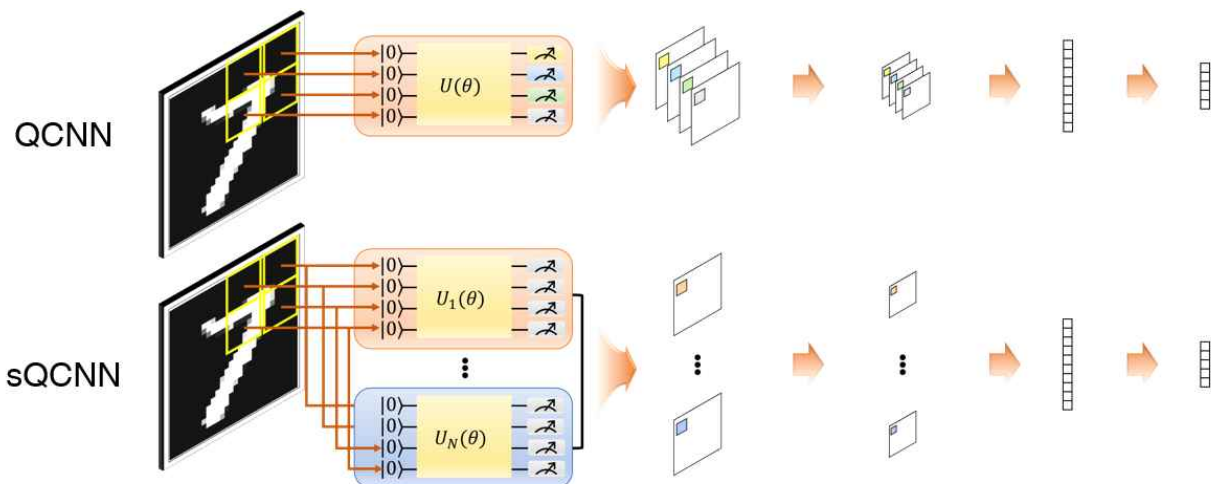


그림 4 스케일러블한 QCNN [18]



양자 컴퓨팅 과정 그 자체의 개선을 이루고자 하였다. 따라서, 양자 회로의 측정 과정 그리고 입력되는 양자 정보의 인코딩 기법 같이 양자 회로에 제한되지 않고 성공적으로 성능을 개선시킬 수 있었다. 이런 연구들은 고전적 강화학습에 구속 받지 않고 양자 컴퓨팅이 지니는 특성에 대하여 깊이 고찰하고 해당 특성을 심층 강화 학습에 적용할 수 있었지만, 아직 더 복잡한 환경(예: 이미지를 받는 Atari2600등)에서는 기존 고전 - 양자 혼합 강화학습이 더 좋은 성능을 보이는 등 한계를 보였다[28].

양자 심층 강화학습이라는 분야는 양자적 특성을 강화 학습의 결합한 지식의 축적으로 이어졌고, 이는 최근 양자 심층 다중 에이전트 강화학습에 대한 연구로 발전하였다. 그림 5은 양자 심층 다중에이전트 강화학습을 나타낸다. 양자 심층 다중 에이전트 강화학습은 기존의 양자 심층 강화학습과 달리 다수의 에이전트를 사용한다. 이것이 의미하는 바는, 만약 총  $N$ 개의 에이전트가 사용된다면, 단일 에이전트가 사용될 때 필요한 연산량의  $N$ 배의 연산량이 요구된다는 뜻이다 (Naïve한 구현방법을 사용한다 가정). 또한, 양자 컴퓨팅이 위에서 언급된 NISQ 특성으로 인해 제한된 크기의 입력 상태 정보를 사용해야 한다는 점을 고려한다면, 양자 다중 에이전트 강화학습은 결코 구현하기 쉬운 작업은 아니다. 따라서, 이를 가능케 만들기 위해서 학습에 필요한 큐비트 숫자를 줄이는 강화 학습 기법이 연구되었다[8]. 해당 연구에서는 큐비트 숫자를 줄이기 위해 중앙학습-탈중앙추론 (Centralized Training Decentralized Execution) 방식의 다중 에이전트 강화학습의 구조를 활용하여 학습의 과정에서 기기에 가해지는 연산 overhead를 최소화하고자 하였다. 추가적으로, 기존에 사용되지 않았던 4변수 밀집 인코딩 기법을 활용함으로써 큐비트의 숫자를 16개에서 4개로 축소시킴과 동시에 정보의 손실량은 최소화시키는 연구를 진행하였다. 해당 연구에서는 다중 에이전트들 간의 협력적인 행동을 이끌어내는데 성공하였다. 그뿐만 아니라, 기존 다중 에이전트 강화학습과 비교했을 때, 확연히 작은 모델과 적은 파라미터를 사용하였음에도 불구하고 제시된 모델은 동등하거나 더 좋은 성능을 낸다는 것을 입증할 수 있었다. 지금까지 고전-양자 혼합 강화학습, 양자 심층 강화학습, 양자 심층 다중 에이전트 강화학습에 대해 소개하였다. 연구가 진행될수록 고전적 강화학습을 모방한 양자 강화학습이 아니라 양자 컴퓨팅의 고유 특성을 많이 고려하여, 양자 컴퓨팅의 고유한 모델을 만들어내는 연구가 이루어지고 있음을 확인할 수 있다. 최근 양자 심층학습에 대하여 나아가야 할 방향에 대해 많은 논의가 이뤄지고 있다[9]. 첫번째 논의점은 양자 컴퓨팅과 고전 강화학습이 만나는 연결고리를 양자 커널 관점에서 분석하고 설계해야 한다는 것이다. 두번째는 양자 옵티마이저에 대한 연구의 필요성이 매우 절실하게 느껴지고 있다는 점이다. 실제 양자 심층 강화학습에서는 심각한 Barren

Plateau의 문제점을 알고 있다. 이 문제의 큰 원인은 아직 양자 파라미터를 제대로 최적화할 수 있는 옵티마이저가 존재하지 않고 대부분 고전적 옵티마이저에 의존하고 있기 때문이다. 해당 문제를 해결하기 위해서는 양자 옵티마이저에 대한 충분한 연구가 이뤄져서, 양자 파라미터를 제대로 최적화할 수 있게 되어야지만 barren plateau를 극복할 수 있을 것이다. 마지막으로, 양자 심층 강화학습에 적합한 양자 게이트에 대한 연구 역시 추후에 많은 연구를 요하는 분야이다.

## IV. 양자 분산 학습

딥러닝은 이미 다양한 데이터 처리 작업을 위한 최첨단 기술이 되었지만, 데이터 보안 및 계산 의존도가 높아 데이터 보안 및 계산 과부하 문제가 종종 발생한다. 이 문제를 해결하기 위해 기존 딥러닝 방법에서는 분산학습 기법이 등장하였다. 연합 학습(Federated learning), 스플릿 러닝(Split learning) 등 분산 학습은 의료, 금융 및 안면 인식과 같이 개인 정보에 민감한 데이터를 처리하는 연구 분야에서 특히 유용하며, 민감한 데이터가 증가하는 추세를 고려할 때 양자 분산 학습은 양자 딥러닝 및 분산 학습의 장점을 결합하여 자연스럽게 분화된 연구 분야이다. 양자 분산 학습은 기존 양자 딥러닝의 제한된 큐비트로 인해 양자 컴퓨터의 확장성에 어려움을 겪기 때문에 이전 분류[18,20,21]와 같은 간단한 작업을 통해 타당성을 입증하였다. 또한 초기 양자 분산 학습은 그림 6와 같이 사실상 고전 신경망을 양자 신경망으로 대체하는 방식이었다.

큐비트 제약 조건을 해결하기 위해, Chen et al. [19]은 처음으로 연합 학습 환경에서 양자-고전 혼합 방식의 인공지능망 방식을 채택하여, 분산하여 학습하는 방식이 제안하였다. 특히, 양자 인공지능망을 사전 훈련된 고전적 인공지능망인 VGG16과 결합하는 것을 고려하였는데, 이는 직접적으로 큐비트 개수의 제약을 완화하기 때문이다. 양자 분산학습에서는 연합 학습에서 널리 사용되는 local gradient를 평균 연산을 위해 global gradient를 얻어내는 FedAvg 알고리즘을 사용하였다 [22].

또한 양자 분산학습은 서버와 클라이언트 간의 보안 양자 통신 프로토콜을 활용하여 외부 공격으로부터 데이터 보안을 강화하는 방식으로 연구가 진행되었다. 구체적으로, 연합 양자 분산 학습[13] 및 양자 연합 학습은 블라인드 양자 컴퓨팅[14]을 적용한 연구로, 연합 학습의 속도 향상 및 학습 시 교환하는 gradient attack으로부터 개인 정보 보호를 달성하기 위한 것이다. 로컬 장치의 개인 데이터를 노출하지 않고 원격 양자 서버를 사용하는 범용 블라인드 양자 계산 프로토콜(UBQC: Universal Blind Quantum Computation Protocols)을 활용한 분산 학습용 양자 프로토콜이 모든 양자 회로, 양자 입력 및 양자 출력에 적용할 수 있기 때문에 양자 분산 학습의 핵심 블



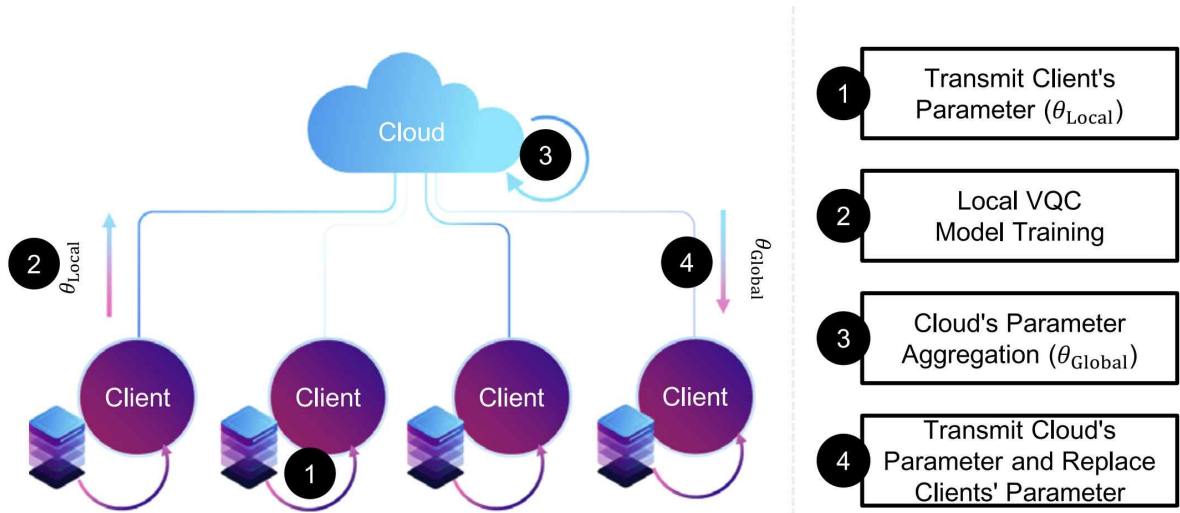


그림 6 양자 분산 학습 파이프라인 [14]

라인드 양자 컴퓨팅으로써 활용되고 있다 [23].

이 밖에도, 최근 연구에서는 그림 7와 같이 발전된 양자 분산 학습 알고리즘을 무선 통신과 결합한 연구를 하였다 [11,30]. 기 연구와 달리, 해당 연구에서는 VQC 학습과 측정 축 학습으로 분리하였으며, 통신 환경에서 중첩 코딩과 연속 간섭 제거를 채택한 기법이다. 효율적으로 성능을 내기 위해 local 학습에서 pole-to-angle training의 기법을 도입하였는데, 이는 VQC 파라미터 (angle parameter)은 고정하고 측정 축 파라미터 (pole parameter)를 학습한 뒤, 학습된 축에 대해 angle parameter를 다시 학습하는 구조이다. Local 장치는 무선 통신 환경에서 angle parameter와 pole parameter를 superposition coding하여 서버로 전송하며 서버는 successive interference cancellation을 통해 angle parameter와 pole parameter를 순차적으로 복원해내어 global gradient를 얻어낸다. 통신 환경이 좋을 때는 angle parameter와 pole parameter를 모두 받게 되고, 통신 환경이 나쁠 때는 pole parameter만 받게 되는 동적인 무선 통신을 고려한 연구이다.

이번 장에서 양자 분산 학습에 대해 살펴보았다. 많은 기 연구들이 고전 분산 학습에서 차용한 구조를 많이 사용하였으며, 최근에는 양자 통신과 결합한 양자 분산 학습 및 양자 회로의 양자적 특성을 더욱 활용한 연구들이 제안되고 있음을 확인하였다.

## V. 전망과 결론

고전 컴퓨팅에서 다루기 힘든 고차원 데이터 처리에 양자 컴퓨팅이 핵심적인 솔루션이 될 수 있다. 또한, 본 논문에서 깊




그림 7 Slimmable Quantum Federated Learning [11]

게 다루지 않은 양자 통신 및 양자 블라인드 컴퓨팅 분야는 현재까지 나와 있는 보안 솔루션 중 가장 안전한 솔루션으로 알려져 있다. 양자 인공 지능은 아직까지 인공지능에 비해 걸음마 수준이지만, 최근 data reuploading 및 추가 ansatz 활용을 통해 양자 인공지능망의 scalability 이슈에 대해서도 발전이 이루어지고 있다. 답러닝이 GPU 텐서 연산 및 네트워크 인프라스트럭처가 구축됨에 따라, 디지털 트랜스포메이션을 이룩하게 된 것처럼, 이론적 우위 달성한 양자 컴퓨팅, 양자 통신, 양자 답러닝 알고리즘이 결합한 양자 기술이 근미래에 현재 처

리하기 매우 어렵다고 알려진 Genomic 데이터 처리, 자율 주행 LiDAR 데이터 처리 등에 대해 매우 효율적으로 처리할 것으로 예상된다.

### 참 고 문 헌

- [1] F. Arute et al., Quantum supremacy using a programmable superconducting processor, *Nature*, vol 574, pp.505-510, 2019.
- [2] J. Choi, and J. Kim, A tutorial on quantum approximate optimization algorithm (QAOA): Fundamentals and applications, *Proc. International Conference on ICT Convergence (ICTC)*, 2019.
- [3] J. Choi, and J. Kim, A tutorial on quantum approximate optimization algorithm (QAOA): Fundamentals and applications, *Proc. International Conference on ICT Convergence (ICTC)*, 2019.
- [4] J Choi, S Oh, and J Kim, The useful quantum computing techniques for artificial intelligence engineers, *Proc. IEEE International Conference on Information Networking (ICOIN)*, 2020.
- [5] J Kim, Y Kwak, S Jung, and JH Kim, Quantum scheduling for millimeter-Wave observation satellite constellation, *Proc. IEEE VTS Asia Pacific Wireless Communications Symposium (APWCS)*, 2021.
- [6] Y. Kwak, W.J. Yun, S. Jung, J.-K. Kim, and J. Kim, Introduction to quantum reinforcement learning: Theory and PennyLane-based implementation, *Proc. International Conference on ICT Convergence (ICTC)*, 2021.
- [7] S. Oh, J. Choi, and J. Kim, A tutorial on quantum convolutional neural networks (QCNN), *Proc. International Conference on ICT Convergence (ICTC)*, 2020.
- [8] Y. Kwak, W.J. Yun, S. Jung, J.-K. Kim, and J. Kim, Introduction to quantum reinforcement learning: Theory and PennyLane-based implementation, *Proc. International Conference on ICT Convergence (ICTC)*, 2021.
- [9] Y Kwak, WJ Yun, S Jung, and J Kim, Quantum neural networks: Concepts, applications, and challenges, *Proc. International Conference on Ubiquitous and Future Networks (ICUFN)*, 2021.
- [10] S Oh, J Choi, JK Kim, and J Kim, Quantum convolutional neural network for resource-efficient image classification: A quantum random access memory (QRAM) approach, *Proc. IEEE International Conference on Information Networking (ICOIN)*, 2021.
- [11] WJ Yun, JP Kim, S Jung, J Park, M Bennis, and J Kim, Slimmable quantum federated learning, *Proc. International Conference on Machine Learning (ICML)*, 2022.
- [12] WJ Yun, Y Kwak, JP Kim, H Cho, S Jung, J Park, and J Kim, Quantum multi-agent reinforcement learning via variational quantum circuit design, *Proc. IEEE International Conference on Distributed Computing Systems (ICDCS)*, 2022.
- [13] J Choi, S Oh, and J Kim, A tutorial on quantum graph recurrent neural network (QGRNN), *Proc. IEEE International Conference on Information Networking (ICOIN)*, 2021.
- [14] Y Kwak, WJ Yun, JP Kim, H Cho, J Park, M Choi, S Jung, J Kim, Quantum distributed deep learning architectures: Models, discussions, and applications, *ICT Express*, 2022.
- [15] WJ Yun, J Park, J Kim, Quantum multi-agent meta reinforcement learning, *arxiv preprint*, 2022.
- [16] J Choi, S Oh, J Kim, Quantum Approximation for Multi-Scale Scheduling, *arxiv preprint*, 2020.
- [17] H Baek, WJ Yun, J Kim, FV-Train: Quantum convolutional neural network training with a finite number of qubits by extracting diverse features, *arxiv preprint*, 2022.
- [18] H Baek, WJ Yun, J Kim, Scalable quantum convolutional neural networks, *arxiv preprint*, 2022.
- [19] S.Y.-C. Chen, S. Yoo, Federated quantum machine learning, *Entropy* vol. 23, no. 4 2021.
- [20] J.R. McClean, S. Boixo, V.N. Smelyanskiy, R. Babbush, H. Neven, Barren plateaus in quantum neural network training landscapes, *Nature Communications*, vol. 9, no. 1, pp.1-6, 2018.
- [21] R. Huang, X. Tan, Q. Xu, Quantum federated learning with decentralized data, *IEEE Journal*

- of Selected Topics on Quantum Electronics  
vol. 28 no. 4, pp. 1-10, 2022.
- [22] B. McMahan, E. Moore, D. Ramage, S. Hampson, B.A. y Arcas, Communication-efficient learning of deep networks from decentralized data, Proc. International Conference on Artificial Intelligence and Statistics (AISTATS), vol. 54, 2017, pp. 1273-1282.
- [23] O. Gupta, R. Raskar, Distributed learning of deep neural network over multiple agents, JNCA vol. 116, pp. 1-8, 2018.
- [24] I. Cong et al., Quantum Convolutional Neural Networks, arxiv preprint, 2018.
- [25] D. Silver, J. Schrittwieser, K. Simonyan, I. Antonoglou, A. Huang, A. Guez, T. Hubert, L. Baker, M. Lai, A. Bolton, et al., "Mastering the game of go without human knowledge." Nature, vol. 550, no. 7676, pp. 354, 2017.
- [26] S. Y.-C. Chen, C.-H. H. Yang, J. Qi, P.-Y. Chen, X. Ma, and H.-S. Goan, "Variational quantum circuits for deep reinforcement learning," IEEE Access, vol. 8, pp. 141 007-141 024, 2020.
- [27] S. Jerbi, C. Gyurik, S. Marshall, H. J. Briegel, and V. Dunjko, "Variational quantum policies for reinforcement learning," in Proc. Neural Information Processing Systems (NeurIPS), December 2021.
- [28] O. Lockwood and M. Si, "Playing Atari with hybrid quantum-classical reinforcement learning," in Proc. NeurIPS 2020 Workshop on Preregistration in Machine Learning, December 2021, pp. 285-301.
- [29] —, "Reinforcement learning with quantum variational circuit," in Proc. AAAI Conference on Artificial Intelligence and Interactive Digital Entertainment (AIIDE), October 2020.
- [30] M. Schuld and N. Killoran, "Is quantum advantage the right goal for quantum machine learning?" CoRR, vol. abs:2203.01340, 2022.



김 중 헌

2004년 2월 고려대학교 컴퓨터학과 학사  
2006년 2월 고려대학교 컴퓨터학과 석사  
2014년 8월 미국 USC Computer Science 박사  
2006년 1월 - 2009년 8월 LG전자 CTO부문 연구원  
2013년 9월 - 2016년 2월 미국 인텔 본사 연구원  
2016년 3월 - 2019년 8월 중앙대 컴퓨터공학부 조교수  
2019년 9월 - 현재 고려대 전기전자공학부 부교수

<관심분야> 퀀텀 답러닝, 심층강화학습, 모빌리티 기술



윤 원 준

2021년 2월 고려대학교 공과대학 전기전자공학부 학사  
2020년 3월 - 현재 고려대학교 인공지능 및 모빌리티 연구실 연구원  
2021년 3월 - 현재 고려대학교 공과대학 전기전자공학과 박사과정  
2022년 6월 - 8월 Cipherome Inc. 실리콘밸리 연구원

<관심분야> Quantum Machine Learning, Federated Learning, Artificial Intelligence





백 한 결

2020년 2월 고려대학교 공과대학 전기전자공학부 학사  
 2020년 2월 - 2021년 2월 LG전자 연구원  
 2021년 3월 - 현재 고려대학교 공과대학 전기전자공학과 박사과정  
 2021년 3월 - 현재 고려대학교 인공지능 및 모빌리티 연구실 연구원

<관심분야> Quantum Machine Learning, Federated Learning, Artificial Intelligence



김 재 평

2023년 2월 고려대학교 공과대학 전기전자공학부 학사  
 2022년 3월 - 현재 고려대학교 인공지능 및 모빌리티 연구실 연구원

<관심분야> Quantum Machine Learning, Federated Learning, Artificial Intelligence